



**UNIVERZITET U NOVOM SADU
FAKULTET TEHNIČKIH NAUKA**



**UNIVERZITET U NOVOM SADU
FAKULTET TEHNIČKIH NAUKA
NOVI SAD**

**Departman za računarstvo i automatiku
Odsek za računarske upravljačke sisteme**

PROJEKTNI ZADATAK

Kandidat: Dušan Vukanić

Broj indeksa: RA 79/2022

Predmet: Softverski algoritmi u sistemima automatskog upravljanja

**Tema rada: Model mašinskog učenja za predviđanje uspešnosti prodaje
BMW automobila**

Novi Sad, septembar, 2025.

Sadržaj

Uvod..... 3

Skup podataka (Dataset)..... 4

Pretprocesiranje..... 5

Eksplorativna analiza..... 6

Modeli i algoritmi..... 7

Analiza rezultata..... 8

Zaključak..... 9

1.Uvod

Tema projekta je analiza i omogućavanje predviđanja uspešnosti prodaje automobila marke BMW, pomoću mašinskog učenja, upotrebom klasifikacionih algoritama. U pitanju je podela na 2 kategorije, High i Low, u zavisnosti od nekoliko faktora koji utiču na uspešnost prodaje. Podaci mogu biti od velikog značaja za formiranje buduće strategije poslovanja kompanije, tj. iz njih može da se predvidi na primer u kom regionu će imati uspeha u prodaji ili koji tip pogonskog goriva je traženiji na pojedinim tržištima. Za izradu projekta korišćen je programski jezik Python, uključujući ugrađene biblioteke potrebne za realizovanje svih modela. U izradi projekta prošlo se kroz nekoliko osnovnih koraka:

1. Pretprocesiranje skupa podataka
2. Eksplorativna analiza
3. Biranje i treniranje modela obuke
4. Podešavanje hiperparametara sa unakrsnom validacijom
5. Analiziranje rezultata i provera kvaliteta (uspešnosti) predikcije
6. Biranje najbitnijih atributa
7. Grafičko predstavljanje dobijenih rezultata

2. Skup podataka (Dataset)

Analiza je vršena na skupu od 50000 podataka, koji prikazuju dosadašnje trendove prodaje BMW vozila širom sveta. Parametri koji su dati su redom:

1. Model automobila
2. Godina kada su podaci prikupljeni
3. Regija na koju se odnose ostali podaci iz kolone
4. Boja automobila
5. Vrsta goriva
6. Tip menjača
7. Veličina motora (u litrima)
8. Kilometraža
9. Cena u američkim dolarima
10. Obim prodaje
11. Step en uspeha prodaje (opisno)

Među datim podacima nema velikog stepena korelacije kada je reč o osobinama automobila, ali postoji korelacija između obima prodaje (kolona Sales_Volume) i stepena uspeha prodaje (kolona

Sales_Classification). Ta kolona se može slobodno izbaciti, da ne bi došlo do overfitting – a modela.


Klasi Low pripada 32754 podatka, a klasi High 15246 podataka. To znači da postoji disbalans između 2 klase, pa je potrebno izbalansirati podatke, čime se smanjuje mogućnost ignorisanja manje zastupljene klase.

3. Pretprocesiranje


Posle učitavanja podataka iz fajla, prvi korak je uklanjanje praznih redova i uklanjanje duplikata ugrađenim funkcijama `dropna` i `drop_duplicates`. Što se ovih kriterijuma tiče, dati set je veoma dobar, jer uopšte nema praznih linija. Nakon tog prvog pretprocesiranja, treba izbaciti čudne vrednosti, tj. outlier – e, što je urađeno pomoću IQR algoritma, a pre toga sam eliminisao nelogične vrednosti koje „na oko“ nemaju smisla, kao na primer negativna kilometraža, cena od nula dolara i slično. Sastavni deo pretprocesiranja je enkodiranje podataka koji u tabeli nisu numeričkog nego tekstualnog tipa, radi lakšeg utvrđivanja stepena korelacije sa drugim podacima. Za numeričke podatke sam uradio skaliranje, zbog drastičnih razlika u redovima veličina između atributa, npr. kilometraža u hiljadama km i zapremina motora sa jednocifrenim brojem litara.

4. Eksplorativna analiza

Nakon toga su svi podaci stavljeni u jedan dataframe i posle toga sam plot – ovao dve heatmape, jednu za upoređivanje stepena prodaje sa cenom, a drugu sa kilometražom, radi lakšeg snalaženja među podacima. Tu je važno napomenuti da sam podelio sve podatke na neke opsege, a nisam uračunao svaku konkretnu vrednost, jer bi bilo nepregledno ukoliko bii postojao po 1 deo za 1, 2, 3, 4,... kilometara. Nakon toga sam i klasama dodelio brojeve 0 i 1 i podelio podatke na trenirajući i testni skup, pomoću ugrađene funkcije iz model_selection biblioteke sklearn. Poslednja stavka u pretprocesiranju je traženje najboljih parametara za svaki model pomoću kros – validacije. Nakon toga plot – ujem classification report, gde se vidi koliko je dobar koji model za dati dataset i funkcija tune_model vraća najbolji model.



Slika 1 – Heatmap koji prikazuje odnos cene automobila i uspešnosti prodaje



Slika 2 – Heatmap koji prikazuje odnos kilometraže i uspešnosti prodaje

5. Modeli i algoritmi

Za procesiranje podataka i proces mašinskog učenja koristio sam četiri algoritma:

1. Logistička regresija
2. Stablo odlučivanja
3. Random Forest
4. XGBoost

Sva četiri algoritma su klasifikacioni algoritmi. Osim što je zadato specifikacijom zadatka, logično je da je problem klasifikacione prirode, jer imamo 2 klase na koje su podaci podeljeni, a ne veliki skup izlaznih vrednosti.

Za logističku regresiju kao parametre prosleđujem maksimalan broj iteracija, za koji sam uzeo vrednost 500, da algoritam ne bi divergirao (ako uzmemo previše), a kao hiperparametre hiperparametar regularizacije C i vrstu kazne l2, što je zapravo Ridge regularizaciju.

Za Random Forest imamo n_estimators, što predstavlja broj stabala u modelu. Ne sme se uzeti previše, zbog overfittinga, a ni premalo, zbog underfittinga. Postoji i maksimalna dubina stabla, kao i kriterijumi Gini i Entropy.

Za Decision Tree imamo maksimalnu dubinu stabla i kriterijume Gini i Entropy.

Algoritam XGBoost je komplikovaniji od ostalih, ali u nekim slučajevima može dati bolje rezultate, pa sam ga zbog toga upotrebio. Njemu se prosleđuje n_estimators, maksimalna dubina, ali i brzina učenja. Ne smemo uzeti preveliku vrednost za learning rate, jer je u tom slučaju veliki rizik od overfitting-a.

Classification Report:				
	precision	recall	f1-score	support
0	0.92	0.85	0.89	6949
1	0.86	0.93	0.90	6953
accuracy			0.89	13902
macro avg	0.89	0.89	0.89	13902
weighted avg	0.89	0.89	0.89	13902

Slika 3 – Classification report za algoritam Random Forest

Model_encoded: 0.096
Year: 0.103
Region_encoded: 0.071
Color_encoded: 0.067
Fuel_encoded: 0.052
Transmission_encoded: 0.026
Engine_Size_L: 0.141
Mileage_KM: 0.222
Price_USD: 0.223

Slika 4 – Feature importances za algoritam Random Forest

6. Analiza rezultata


Za biranje najboljeg od svih iskorišćenih modela neophodno je uporediti performanse sva 4 modela, a nakon toga ustanoviti i koji su atributi podataka najbitniji, a koji su manje bitni, kada je reč o uticaju na uspešnost prodaje automobila. Pre toga se odrede najbolji hiperparametri za model, koji doprinose uspešnosti samog predviđanja. Na datom skupu podataka najbolje se pokazao Random Forest model, jer je njegova tačnost čak 0.891, a preciznost je 0.92 za nultu i 0.86 za prvu klasu. Njegovi rezultati takođe ukazuju na to da je za dobru prodaju vozila na nekom tržištu ključna cena i kilometraža, jer je njihova vrednost za importance najveća. S druge strane, logistička regresija se ovde pokazala kao prilično neuspešna, jer joj je tačnost manja od 0.5, kao i preciznost za obe klase, a takođe ima i loš F1 score i recall, tj. odziv. F1 score zavisi od zbira i proizvoda preciznosti i odziva, pa je i logično da njegova vrednost zavisi od ova 2 parametra. Kada se radi samo sa pet najbitnijih atributa, umesto sa svih deset, kod Random Foresta, tačnost je sada oko 0.86, dok je npr. za nultu klasu preciznost opala sa 0.92 na 0.85, što i dalje nije mnogo, tako da je možda i bolje uzimati samo prvih 5 atributa u ovom slučaju, jer nije velika razlika u predviđanju, a štedi dosta procesorskog vremena, pa se program brže izvršava. Takođe, ovaj model je i dalje najbolji od sva četiri, pa ga treba ponovo iskoristiti za najbolji učinak.

Classification Report:					
	precision	recall	f1-score	support	
0	0.85	0.86	0.86	6949	
1	0.86	0.85	0.86	6953	
accuracy			0.86	13902	
macro avg	0.86	0.86	0.86	13902	
weighted avg	0.86	0.86	0.86	13902	

Slika 5 – Classification Report za 5 najbitnijih atributa kod algoritma Random Forest

7. Zaključak

Od data četiri upotrebljena modela, ubedljivo najbolje se pokazao model Random Forest, a takođe da se može koristiti i samo sa nekoliko najbitnijih atributa, što pritom neće mnogo uticati na kvalitet predviđanja, a skratice vreme treniranja modela i izvršavanja. Najvažniji parametri su cena vozila i broj pređenih kilometara, a zavisnost podela klase od njih je prikazana na krajnjem plotu. Klase se dosta preklapaju, zbog toga što to nisu jedine performanse koje utiču na popularnost određenog modela. Upotrebljeno je log skaliranje, da bi se jasnije prikazali svi podaci, jer ih ima 50000, pa se, ako to ne uradimo, zbog loše rezolucije sve preklapaju na grafiku i prikaz postaje nejasan.



Slika 6 – Klasifikacija na osnovu dva najbitnija parametra – cene i kilometraže

Što se tiče upotrebe mašinskog učenja, to je izuzetno koristan način obrade podataka i predviđanja budućih trendova, a primena je veoma široka u svim oblastima. Na ovom konkretnom primeru vidimo kako se skup od 50000 podataka može obraditi i osposobiti za predikciju za svega nekoliko minuta, za šta bi inače trebalo i više od jednog dana, a verovatno neke stvari ne bi ni bile moguće. To olakšava posao analize tržišta i sprečava velike finansijske gubitke.